

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ»
(СПбГУ)

Образовательная программа бакалавриата «Науки о данных»



Отчёт по практике
Учебная практика (научно-исследовательская работа)

Выполнил студент 4 курса бакалавриата
(группа 22.Б05-мкн)

Михеев Артём Антонович

Научный руководитель:
Кандидат физико-математических наук
Николаев Максим Сергеевич

Санкт-Петербург

Текстовые эмбединги финансовых новостей, допускающие восстановление смысла.

Содержание

1. Введение. Постановка задачи. Актуальность.	3
1.1 Введение	3
1.2 Мотивация, актуальность: интеграция в мультимодальную модель	3
1.3 Формулировка задачи	5
1.4 Полезные статьи	5
2. Основные результаты практики	7
2.1 Основной набор данных	7
2.2 Метрики оценки	7
2.3 Архитектура моделей	8
2.3.1. Подходы на основе RNN	9
2.3.2 Подходы на основе transformer архитектуры.	9
2.4 Обучение	11
2.5 Графики	12
2.6 Анализ размерностей и типа архитектуры	14
2.7 Генерация	15
2.8 Функция потерь на уровне смыслов предложений	16
2.8.1.sent_sim_loss	16
2.8.2 loss на перефразе	17
2.9 Изучение полученных эмбедингов	19
2.9.1. добавление шума	19
2.9.2 визуализация с помощью PCA	20
3.Примеры восстановления.	20
3.1. заголовки	20
3.2. новостные описания	21

4. Заключение	22
4.1. Основные результаты	22
4.2. Направления дальнейших исследований	22

1. Введение. Постановка задачи. Актуальность.

1.1 Введение

Настоящая работа посвящена проектированию и обучению компактного автокодировщика текста (encoder–decoder), порождающего единый вектор фиксированной размерности, из которого текст может быть восстановлен с сохранением основного смысла.

1.2 Мотивация, актуальность: интеграция в мультимодальную модель

Рассмотрим задачу построения мультимодальной модели, которая на основе разнородных входных данных — числовых финансовых временных рядов, табличных данных, новостного контекста — предсказывает финансовые показатели (фондовые индексы, валютные курсы, вероятность дефолта) и одновременно порождает текстовую интерпретацию, объясняющую причины изменения этих показателей.

Прямая авторегрессионная генерация текста в составе такой модели нежелательна: функция потерь в этом случае будет наполнена текстовой компонентой, ухудшая качество предсказания числовых показателей. Предлагаемый подход решает эту проблему следующим образом:

- 1. Предобработка (препроцесс).** Для обучающего набора данных, интерпретации кодируются обученным encoder в латентные векторы. После этого encoder исключается из пайплайна.
- 2. Обучение мультимодальной модели.** Мультимодальная модель обучается предсказывать латентный вектор интерпретации по входному контексту. (В генеративной парадигме, так и с использованием cosine similarity loss.)

3. **Декодирование.** Предсказанный вектор подаётся в обученный decoder, который восстанавливает текстовую интерпретацию. При необходимости decoder может быть дообучен совместно с мультимодальной моделью.

Данная схема предъявляет два принципиальных требования к автокодировщику:

- **Компактность модели.** Decoder должен быть достаточно лёгким для быстрого декодирования вспомогательных интерпретаций в режиме инференса.
- **Представление в виде единого вектора.** Латентное представление должно быть вектором фиксированной размерности, а не последовательностью скрытых состояний (как, например, в линейных трансформерах или рекуррентных моделях), поскольку мультимодальная модель должна иметь возможность предсказывать именно один вектор.

Предложенный подход является универсальным: обученная пара encoder–decoder может быть перенесена на новые задачи без переобучения. Для адаптации к новой предметной области достаточно обучить мультимодальную модель предсказывать латентные векторы по контексту соответствующей задачи.

1.3 Формулировка задачи

Основная задача работы состоит в проверке гипотезы о возможности конструирования компактного текстового эмбединга (единого вектора фиксированной размерности S), допускающего восстановление исходного текста с сохранением семантического содержания. Формально требуется построить:

- **Encoder** $E:S \rightarrow RS$, отображающий входной текст в вектор,
- **Decoder** $D:RS \rightarrow S$, восстанавливающий текст из вектора,

такие что $D(E(x))$ семантически близок к x для произвольного входного текста $x \in X$.

Дополнительно исследуются:

- зависимость качества восстановления от размерности S ;
- свойства локальности латентного пространства;
- влияние различных функций потерь на качество восстановления.


1.4 Полезные статьи

Тема сжатия текста в компактные латентные представления с возможностью восстановления активно исследуется в последних работах.


Kuraton et al. [1] показали, что замороженная LLM способна авторегрессионно восстанавливать до 1568 токенов из единственного обучаемого вектора ([mem]-токена), оптимизируемого для каждого текста индивидуально. Mezentsev, Oseledets [2] продемонстрировали, что аналогичное восстановление возможно за один прямой проход (non-autoregressive) всего из двух обучаемых «прото-токенов», при этом множество решений обладает связностью и почти выпуклостью. Обе работы, однако, не строят отдельного encoder: для каждого нового текста требуется индивидуальная оптимизация эмбедингов (тысячи шагов градиентного спуска), что исключает применение в реальном времени. Построение практического encoder обозначено в обеих работах как открытая задача.

Настоящая работа решает именно эту задачу: обучается полноценный encoder, кодирующий произвольный текст в единый вектор за один прямой проход, и компактный decoder, восстанавливающий текст из этого вектора. Кроме того, в отличие от [1, 2], где целью является точное восстановление

последовательности токенов, здесь фокус смещён на восстановление смысла, а архитектура проектируется для интеграции в мультимодальный пайплайн.



прямой



авторегрессионный

2. Основные результаты практики

2.1 Основной набор данных

Для обучения и оценки моделей используется набор данных [Financial News Headlines Data](#) с платформы Kaggle. Набор содержит заголовки финансовых новостей, собранные с официальных сайтов CNBC, The Guardian и Reuters, и отражает обзор экономики и фондового рынка США за период 2018–2020 гг.

Общий объём: 53 370 заголовков. Разбиение: 90% — обучающая выборка, 10% — валидационная.

Примеры заголовков:

- *U.S. economy faces significant risks, long road to recovery: IMF staff.*
- *UBS, Morgan Stanley expected to lead Vodafone Tower IPO: sources.*
- *As big U.S. banks let customers delay payments, loan losses remain unclear.*
- *China says it will act to protect its interests after UK Huawei ban.*

2.2 Метрики оценки

Для оценки качества восстановления текста используются следующие метрики.

1. Accuracy (совпадение токенов)

Доля токенов, в которых предсказанный совпадает с исходным, при позиционном сопоставлении.

2. BERTScore

Семантическая метрика на основе модели [microsoft/deberta-xl-large-mnli](#). Для каждого токена одного предложения находится наиболее близкий токен в другом предложении по косинусному сходству; вычисляются Precision, Recall и F1 на основе агрегированных значений сходства. Вычислительная сложность — $O(T^2)$.

Примеры:

- `bert_score( "The car was damaged in the accident.", "The vehicle got wrecked during the crash." ) = 0.91`
- `bert_score( "The economy is growing rapidly.", "My dog loves running in the park." ) = 0.35`

3. Paraphrase Similarity (paraph_sim)

Косинусное сходство между эмбедингами предложений, полученными с помощью модели [sentence-transformers/paraphrase-mpnet-base-v2](#). Каждое предложение отображается в вектор размерности 768.

Примеры:

- `paraph_sim( "The car was damaged in the accident.", "The vehicle got wrecked during the crash." ) = 0.821`

- `paraph_sim( "The economy is growing rapidly.", "My dog loves running in the park." ) = 0.17`

2.3 Архитектура моделей


B - batch_size

T - длина предложения в токенах с padding для обучения по бачам.

H - размерность эмбедингов токенов.

S - размерность эмбедингов предложений.


V - размер словаря из токенов.



На вход модели подаётся тензор размера (B, T, H). На выходе logits (B, T, V)

2.3.1 RNN

Подходы на основе RNN не оправдали себя. Обучение векторов напрямую через `mse/cos loss` не сходилось, а авторегрессионная постановка предсказывала следующий токен с `accurasy=0.2`



2.3.2 Подходы на основе transformer архитектуры.

Encoder

Используется предобученная модель FinBERT [3] — модель на основе архитектуры BERT, дообученная для анализа тональности финансовых текстов. На выходе FinBERT формируются контекстуализированные эмбединги для каждого токена и специальный [CLS]-токен.

Для агрегации токеновых эмбедингов в единый вектор предложения рассматриваются два подхода:

1. **CLS-эмбединг.** Используется только представление [CLS]-токена размерности H .
2. **Attention pooling.** Агрегация с обучаемыми весами внимания:

Псевдокод:

```
attn_scores = linear(x)
attn_weights = softmax(attn_scores, dim=1)
sum(attn_weights * projection(x))
```

Attention pooling позволяет варьировать размерность S выходного вектора предложения независимо от размерности модели FinBERT.

Decoder


Обучается с нуля. Рассматриваются два варианта архитектуры.

(1) Прямой декодер (одношаговый).

Основан на архитектуре Transformer Encoder (self-attention без маскирования). Эмбединг предложения $s \in \mathbb{R}^S$ расширяется до последовательности длины T путём добавления позиционных эмбедингов и подаётся в блоки self-attention. Все токены предсказываются одновременно: $P(\text{tgt}[1:T] \mid s)$

(2) Авторегрессионный декодер. Основан на архитектуре Transformer Decoder (masked self-attention + cross-attention). Эмбединг предложения s подаётся как context для cross-attention. Токены генерируются последовательно:

$P(\text{tgt}[n+1] \mid \text{tgt}[1:n], s)$



2.4 Обучение

Число параметров

S	Обучаемые параметры	Необучаемые параметры (FinBERT)
768	38.5 M	109 M
2560	214 M	109 M

Loss: *cross_entropy_loss*

optimizer: AdamW (learning_rate=0.0001, weight_decay=0.01)

lr_scheduler: ReduceROnPlateau (mode='max', factor=0.1, min_lr=1e-5, patience=5)



batch_size: 128-200

2.5 Графики



Train

VALIDATION


Loss




Accuracy



BERT-score



Top-5



2.6 Анализ размерностей и типа архитектуры

Модель	S	Accuracy (valid)	BERTScore
Прямой декодер	1568	0.357	—
Авторегрессионный, CLS	768	0.406	0.58
Авторегрессионный, Attention Pooling	768	0.502	0.65
Авторегрессионный, Attention Pooling	2560	0.552	0.675

Авторегрессионные модели по качеству сильно лучше, но медленнее.

Attention pooling увеличивает качеству по сравнению с *cls* эмбделлингом. Также этот слой позволяет менять размерность *sent_emb*.

Увеличивая размерность вектора, метрики растут.


Как часто входные токены в первых k токенах по вероятности.

Top-k	1	3	5	10	15	25	50	100
S=768	0.50	0.63	0.68	0.73	0.75	0.78	0.81	0.84
S=2560	0.55	0.68	0.72	0.77	0.79	0.81	0.84	0.86


Заметно, что top-5 сильно лучше, чем top-1. С увеличением k скорость роста метрик сильно уменьшается.

2.7 Генерация

Greedy



Beam



Изменив алгоритм генерации с жадного на поиск наиболее вероятной последовательности, модель стала реже заикаться.

beam_width	1	5	10
paraph_sim	0.665	0.687	0.689

2.8 Функция потерь на уровне смыслов предложений

Подход с *cross_entropy_loss* стремится восстановить исходный текст, и никак не учитывает смысл.

Поэтому были придуманы и реализованы функции потерь на уровне смыслов предложений.

2.8.1 *sent_sim_loss*

Работает на уровне семантики целого предложения. Для исходного и восстановленного текста вычисляются эмбединги предложений с помощью внешней модели [sentence-transformers/paraphrase-mpnet-base-v2](#), после чего минимизируется косинусное расстояние между ними:

Выбор модели [paraphrase-mpnet-base-v2](#) обусловлен тем, что она обучена порождать близкие эмбединги для семантически схожих текстов. Использование собственного encoder для этой цели нецелесообразно, поскольку он изначально хуже разделяет семантически различные предложения.

	paraph_model	my_model
I enjoy reading books in my spare time.		
I like reading novels during my free time.	0.918	0.792
Python is a popular programming language.	0.162	0.544

Прямая передача сгенерированных токенов не допускает обратного распространения градиента, применяется Gumbel-Softmax с механизмом Straight-Through Estimator (STE):

Псевдокод:

```
distribution = F.gumbel_softmax(logits, tau=1.0, hard=True)
gen_embs = torch.matmul(distribution, emb_matrix)
emb_gen = paraph_model(inputs_embeds=gen_embs)
```

Результаты. Данная функция потерь оказалась нестабильной при обучении. Её использование в качестве основной функции потерь не привело к улучшению

результатов. Можно применять её только как регуляризатор с малым коэффициентом в сочетании с базовой кросс-энтропией.

2.8.2 loss на перефразах

Поскольку задача состоит в восстановлении *смысла*, а не точной последовательности токенов, предлагается напрямую обучать модель восстанавливать перефразы исходного текста.

gen_paraphrase_model - "ramsrigouthamg/t5-large-paraphraser-diverse-high-quality"

С помощью gen_paraphrase_model создаем Paraphrase Dataset, по 3 перефразы на пример.

Для разнообразной генерации можно изменять параметры.

Параметры генерации: top_k=120, top_p=0.9, temperature=1.7

Пример:

Оригинал	Weak sales growth hits American Eagle outlook; shares slide
Перефраз 1	The American Eagle's outlook is marred by poor sales growth; the stock plummets.
Перефраз 2	The American Eagle's prospects are harmed by poor sales growth;the stock plummets.
Перефраз 3	The American Eagle's prospects suffer as a result of poor sales growth;the stock plummets.

Для каждого обучающего примера генерируются $K=3$ перефразы.

Обозначим $L_0=LCE(x)$ — кросс-энтропию относительно исходного текста,

$L_k=LCE(k)$ — кросс-энтропию относительно k -й перефразы, $k=1,\dots,K$.

Рассматриваются три варианта агрегации.

Вариант 1: Среднее (mean)

$loss=mean(L_0,L_1,L_2,L_3)$

Усреднение учитывает все перефразы, но некачественные перефразы могут негативно смещать оптимизацию.

Вариант 2: Минимум (min)

$loss=min(L_0,L_1,L_2,L_3)$

Минимум устраняет влияние некачественных перефраз, но оптимизирует только одну лучшую (как правило, наиболее близкую к оригиналу), игнорируя сигнал от остальных

Вариант 3: F1-агрегация

$loss=HarmonicMean(L_0,L_1,L_2,L_3)$

Гармоническое среднее по всем компонентам доминируется наименьшими значениями $loss$, тем самым фокусируя оптимизацию на лучших перефразам, но сохраняя вклад остальных. Требует больших вычислительных затрат.

CE: top-5 = 0.77

F1: top-5 = 0.78

На данном этапе улучшение по top-5 ассурасу умеренное. Однако если для каждой перефразы отдельно вычислить top-5 ассурасу и усреднить по всем перефразам, модель с paraphrase loss достигает 0.9 против 0.6 у базовой на обучающем наборе данных.

2.9 Изучение полученных эмбедингов

2.9.1 добавление шума

Для оценки локальности латентного пространства к обученным эмбедингам добавлялся гауссов шум $N(0, \sigma)$ и измерялось качество восстановления:

- При $\sigma=0.1$: $BERTScore(\sigma=0.1) \approx BERTScore(\sigma=0)$
- При $\sigma=1.0$: $BERTScore(\sigma=1.0) < 0.9 \cdot BERTScore(\sigma=0)$

Можно надеяться, что небольшие отклонения от точного вектора, неизбежные при его предсказании мультимодальной моделью, не приводят к критическому ухудшению качества декодирования.

2.9.2 визуализация с помощью PCA



Выполнена проекция латентных векторов на первые главные компоненты методом PCA. Перефразы одного и того же исходного предложения отображаются одним цветом.

3.Примеры восстановления.

3.1 заголовки

Входной текст	Восстановленный текст
nils pratley on finance george osborne must understand the imf role is no popularity contest	nils pratley on finance george osborne must think the imf is no need to comment
oil prices slide as u.s.-china trade war escalates	oil prices slide as u.s.-china trade war escalates
malaysia regulator to probe if airasia broke rules in airbus deals	malaysia regulator to probe airasia in regulators if boeing deals

Пример (2) восстановлен дословно. В примере (1) сохранена тематика и ключевые сущности при изменении формулировки. В примере (3) Airbus заменён на Boeing — компанию из той же отрасли.

3.2 новостные описания

Модель была дополнительно протестирована на более длинных новостных описаниях, существенно превышающих среднюю длину обучающих заголовков (accuracy=0.568, paraph_sim=0.595).

Входной текст	Восстановленный текст
Amazon.com is interested in buying prepaid cellphone wireless service Mobile from U.S. carriers — Mobile US and Sprint Corp, two sources familiar with the matter said on.	Amazon.com is interested in buying wireless carriers from U.S. wireless carriers — Mobile US and Sprint Corp, two sources familiar with the matter said on.
U.S. companies' borrowing to spend on capital investments rose 18% in September from a year earlier, the Equipment Leasing and Association said on.	U.S. companies' borrowings and investments rose to a record high on Monday in April, the North American Association said on.

В первом примере сохранены ключевые сущности (Amazon, Mobile US, Sprint Corp) и общий смысл при незначительном изменении формулировки. Во втором примере сохранена тематика (рост инвестиций американских компаний), однако конкретные числовые детали (18%, September) утрачены — что ожидаемо при сжатии в вектор фиксированной размерности.

4. Заключение

4.1 Основные результаты

Основные цели проекта были достигнуты. Была показана возможность построения текстового эмбединга с возможностью частичного восстановления по смыслу с итоговыми метриками: $\text{paragraph_sim} = 0.69$ ($\text{beam_width} = 5$), $\text{val_accuracy} = 0.659$, $\text{BERTScore} = 0.7$. Были исследованы и реализованы различные архитектуры (прямой и авторегрессионный декодеры, CLS и Attention Pooling), а также предложены специальные функции потерь на

перефразов (sent_sim_loss, mean, min, F1), напрямую отражающие идею восстановления текста, похожего по смыслу.

Работы [1, 2] продемонстрировали существование компактных латентных представлений текста в пространстве входов LLM, однако построение практического encoder было обозначено как открытая проблема. В настоящей работе этот шаг реализован: обучен полноценный encoder, кодирующий произвольный текст в единый вектор.

Данный подход открывает новые возможности для совместной генерации в мультимодальных моделях. Для объяснения изменения финансовых показателей достаточно предсказать один вектор, а обученный decoder сгенерирует текстовую интерпретацию, сохранившую общий смысл.

4.2 Направления дальнейших исследований

Масштабирование decoder-архитектуры. Текущий decoder обучается с нуля, что ограничивает его языковые возможности. Использование предобученных языковых моделей (LLaMA, Pythia) в качестве decoder, инициализированных латентным вектором через cross-attention или prefix-механизм, позволит повысить качество и связность генерируемого текста. Результаты [1] показывают, что замороженные LLM обладают значительной скрытой ёмкостью входных эмбеддингов, что может быть использовано для построения более мощного decoder без полного переобучения.

Интеграция в мультимодальную модель.

Ближайшим шагом является обучение мультимодальной модели предсказанию латентных векторов по финансовому контексту (временные ряды, табличные данные) с последующим совместным дообучением decoder.

Перенос на другие домены. Предложенная схема не привязана к финансовой тематике. Универсальность подхода (выделенный encoder + компактный decoder) открывает возможности для применения в медицинских, юридических

и иных мультимодальных системах, требующих интерпретируемости предсказаний.

Исследование компромисса размерность–качество. Экспериментальные результаты показали монотонную зависимость качества от размерности S . Систематическое построение кривых rate-distortion для обученного encoder и сравнение с теоретическими пределами из [1] представляют самостоятельный интерес.

Список использованных литературных источников
и информационных материалов.

[\[1\] Cramming 1568 Tokens into a Single Vector and Back Again: Exploring the Limits of Embedding Space Capacity](#)

[\[2\] Exploring the Latent Capacity of LLMs for One-Step Text Generation](#)

[\[3\] FinBERT: Financial Sentiment Analysis with Pre-trained Language Models. 2019.](#)

Репозиторий проекта.

[Github: sber_practice](#)