

РЕЦЕНЗИЯ

на выпускную квалификационную работу

Михеева Артёма Антоновича

«Текстовые эмбединги финансовых новостей, допускающие восстановление смысла»

Рецензируемая выпускная квалификационная работа посвящена задаче построения текстового представления, которое одновременно является компактным, имеет фиксированную размерность и допускает последующее восстановление текста с сохранением основного смысла. Ценность работы состоит не только в применении современных нейросетевых архитектур к финансовым новостям, но и в самой постановке вопроса: автор пытается проверить, насколько далеко можно продвинуться в направлении обратимых смысловых эмбедингов, не сводя задачу к обычному получению sentence embeddings.

Такая постановка представляется актуальной и содержательной. В прикладных финансовых сценариях часто требуется объединять числовые временные ряды, табличные признаки и новостной фон, а также получать интерпретируемый текстовый выход. При этом прямое включение полноценной авторегрессионной генерации в основной прогнозный контур может быть слишком тяжёлым и плохо согласованным с оптимизацией числового прогноза. Идея вынести текст в отдельное латентное пространство, а затем предсказывать уже компактный вектор интерпретации, выглядит естественной и практически мотивированной.

С методической точки зрения работа интересна тем, что автор рассматривает жёсткий bottleneck: вся информация о тексте должна быть сосредоточена в одном векторе фиксированной размерности. Это существенно сложнее, чем хранить последовательность скрытых состояний трансформера или использовать готовое представление предложения только для сравнения текстов. В такой постановке модель должна не просто различать близкие и далёкие тексты, а сохранять достаточно информации для последующего декодирования. Именно поэтому задача является исследовательской, а не только инженерной.

В практической части реализован encoder-decoder подход с использованием FinBERT в качестве основы encoder и transformer-декодеров для восстановления текста. Автор не ограничился одним выбранным вариантом архитектуры, а провёл сравнительный анализ нескольких решений: прямого и авторегрессионного декодирования, CLS-представления и attention pooling, разных размерностей латентного вектора, а также разных стратегий генерации. Наличие отрицательных результатов для RNN-подходов также важно: они показывают, что автор действительно исследовал пространство решений.

Экспериментальная часть производит хорошее впечатление. Использован достаточно крупный для учебной работы набор Financial News Headlines Data, включающий более 53 тысяч финансовых заголовков. Качество восстановления анализируется не только через потоковое совпадение, но и через семантические метрики, включая BERTScore и сходство представлений предложений. Такой выбор метрик соответствует сути задачи: при восстановлении смысла дословное совпадение токенов не является единственным и, возможно, не является главным критерием качества.

Полученные результаты в целом выглядят убедительно и хорошо интерпретированы. Автор показывает, что attention pooling оказывается предпочтительнее простого CLS-представления, увеличение размерности латентного пространства улучшает восстановление, а авторегрессионный декодер заметно превосходит прямой декодер. Отдельно отмечу top-k анализ: он показывает, что модель часто помещает правильный токен среди нескольких наиболее вероятных вариантов, то есть ошибки top-1 реконструкции не всегда означают полную потерю информации. Это важное наблюдение для дальнейшего развития метода. Также кажется удачной попытка выйти за пределы обычной cross-entropy реконструкции. Для данной задачи простая потоковая функция потерь поощряет буквальное восстановление исходной последовательности и не всегда соответствует цели сохранения смысла. Автор исследует семантические функции потерь, основанные на сходстве предложений и парафразах.

В то же время у работы есть ограничения, которые важно явно зафиксировать. Во-первых, сохранение общего смысла не гарантирует сохранения фактической точности. Для финансовых новостей замена одной компании на другую, потеря численного значения, изменение направления события или неточная передача контекста могут быть критическими, даже если текст в целом остаётся семантически похожим. Поэтому в дальнейшем метод следует оценивать не только общими семантическими метриками, но и метриками фактической консистентности, включая сохранение именованных сущностей, чисел и причинно-событийных связей. Во-вторых, работа пока скорее демонстрирует реализуемость подхода, чем даёт завершённое решение задачи обратимых текстовых эмбедингов. Было бы полезно расширить эксперименты на более длинные тексты, другие домены финансовой аналитики и более строгие сценарии переноса. Кроме того, литературный обзор можно усилить: в текущем виде он включает небольшое число источников, а по части работ не до конца ясно, где и когда они были опубликованы и как именно они соотносятся с предложенной постановкой.

Несмотря на эти замечания, общее впечатление от работы положительное. Автор продемонстрировал самостоятельность, умение проводить эксперименты, сравнивать архитектурные решения и содержательно обсуждать как положительные, так и отрицательные результаты. Работа содержит полноценную инженерную реализацию и выраженную исследовательскую составляющую, а её результаты можно рассматривать как убедительный прототип подхода к построению компактных смысловых представлений с возможностью декодирования.

Считаю, что выпускная квалификационная работа Михеева Артёма Антоновича «Текстовые эмбединги финансовых новостей, допускающие восстановление смысла» соответствует требованиям, предъявляемым к выпускным квалификационным работам бакалавриата, заслуживает оценки «отлично», а её автор — присвоения степени бакалавра по образовательной программе «Науки о данных».

Рецензент:

Алексей Алексеевич Зайцев

05.06.2026